

BIL462 Makine Öğrenmesi – Final Sınavı

Süre / Duration: 40 dakika

Açıklamalar / Instructions: Her soruda hem Türkçe hem İngilizce birer cümle ve her cümlede bir boşluk bulunmaktadır. Boşluklardan **yalnızca birini**, terimin Türkçe ya da İngilizce karşılığı ile doldurabilirsiniz. Her iki dilde verilen cevaplar kabul edilecektir.

(Each question contains one blank in a Turkish sentence and one blank in an English sentence. Fill **only one** of these blanks with the appropriate term in either Turkish or English. Both languages will be accepted.)

Her kısım 20 puandır.

1 Denetimli (Supervised) ve Denetimsiz (Unsupervised) Öğrenme

1. Denetimli (supervised) öğrenmede eğitim verisi girdi-çıkıttı çiftleri içerir; oysa **denetimsiz (unsupervised)** öğrenmede veri sadece girdilerden oluşur, hedef etiket yoktur. (In supervised learning the training data contains input-output pairs, whereas in **unsupervised** learning the data consists only of inputs with no target labels.)
2. Ev büyüklüğü, konum ve yaş bilgilerinden ev fiyatını tahmin etmek bir **regresyon (regression)** görevidir ve **denetimli (supervised)** öğrenme kapsamındadır. (Predicting house prices from size, location, and age is a **regression** task and falls under **supervised** learning.)
3. Müşterileri satın alma geçmişlerine göre önceden tanımlanmış kategoriler olmadan gruplandırmak bir **denetimsiz (unsupervised)** öğrenme görevidir, özellikle **kümeleme (clustering)** olarak adlandırılır. (Grouping customers based on purchase history without predefined categories is an **unsupervised** learning task, specifically called **clustering**.)
4. PCA gibi boyut indirgeme teknikleri genellikle **denetimsiz (unsupervised)** kabul edilir çünkü hedef etiket kullanmazlar. (Dimensionality reduction techniques like PCA are generally considered **unsupervised** because they do not use target labels.)

2 Sınıflandırma (Classification) ve Kümeleme (Clustering)

1. **Sınıflandırmada (classification)** model kesikli kategori etiketleri tahmin eder; **kümelemede (clustering)** ise algoritma etiketsiz veride doğal grupları keşfeder. (In **classification** the model predicts discrete category labels, whereas in **clustering** the algorithm discovers natural groupings in unlabeled data.)

2. k-ortalamlar (k-means) bir **kümeleme (clustering)** algoritmasıdır; lojistik regresyon bir **sınıflandırma (classification)** algoritmasıdır. (k-means is a **clustering** algorithm; logistic regression is a **classification** algorithm.)
3. E-postaları “spam” ve “spam değil” olarak ayıran bir model **ikili sınıflandırma (binary classification)** yapar. Haberleri “siyaset”, “spor”, “teknoloji” gibi gruplara ayıran model ise **çok sınıflı sınıflandırma (multi-class classification)** yapar. (A model that distinguishes between “spam” and “not spam” emails performs **binary classification**. A model that sorts news articles into “politics”, “sports”, and “technology” performs **multi-class classification**.)
4. Doğru mu Yanlış mı: Kümeleme algoritmaları eğitim verisinde bir hedef değişkenin bulunmasını gerektirir. **Yanlış (False)** (True or False: Clustering algorithms require a target variable in the training data. **False**)

3 Veri Bölme: Eğitim, Doğrulama, Test (Train, Validation, Test), cross-validation

1. Bir veri kümesinin tipik üç ayrık alt kümeye ayrılması: modeli eğitmek için **eğitim (training)** kümesi, hiperparametreleri ayarlamak için **doğrulama (validation)** kümesi ve yalnızca son değerlendirme için kullanılan **test (test)** kümesi. (The typical split of a dataset consists of three disjoint subsets: the **training** set used to fit the model, the **validation** set used to tune hyperparameters, and the **test** set used only for final evaluation.)
2. Aşırı öğrenme (overfitting), genellikle **eğitim (training)** kümesindeki başarımın **doğrulama/test (validation/test)** kümesinden çok daha yüksek olmasıyla fark edilir. (Overfitting is often detected when the performance on the **training** set is much higher than on the **validation/test** set.)
3. **Test** kümesi, model seçimi veya hiperparametre ayarlama sırasında **asla** kullanılmamalıdır. (The **test** set should **never** be used during model selection or hyperparameter tuning.)
4. 1000 örnekli bir veri kümesinde %20’sini test için ayırdıktan sonra kalan veriyi 80/20 eğitim/doğrulama olarak bölersek, son doğrulama kümesindeki örnek sayısı **160** olur. (If a dataset has 1000 samples, and we hold out 20% as a test set, then split the remaining data 80/20 for training/validation, the final validation set size is **160**.)
5. **k-katlı çapraz doğrulama (k-fold cross-validation)**, veriyi k eşit parçaya bölüp $k - 1$ ’i üzerinde eğitim yapıp kalan parçada değerlendirme işlemini k kez tekrarlayan bir tekniktir. (**k-fold cross-validation** is a technique that divides the data into k equal parts, trains on $k - 1$ of them, and evaluates on the remaining one, repeating k times.)
6. Çapraz doğrulamanın basit bir eğitim/doğrulama bölmeye göre en büyük avantajı, model başarımının daha **güvenilir (reliable)** bir tahminini vermesi ve rastgele bölmeden kaynaklanan değişimi azaltmasıdır. (The main advantage of cross-validation over a simple train/validation split is that it provides a more **reliable** estimate of model performance and reduces variance due to a particular random split.)
7. **Tabakalı (stratified)** k-katlı çapraz doğrulamada her katmanda sınıf oranları korunur; bu özellikle **dengesiz (imbalanced)** veri kümeleri için önemlidir. (In **stratified** k-fold cross-validation,

the class proportions are preserved in each fold, which is especially important for imbalanced datasets.)

4 Aşırı Öğrenme, Yetersiz Öğrenme, Genelleme, Aşırı Parametrelendirme (Overfitting, Underfitting, Generalization, Over-parameterization)

1. Eğitim verisini fazla iyi öğrenip gürültüyü ve rastgele dalgalanmaları da yakalayan model **aşırı öğrenme (overfitting)** sorunu yaşar. Eğitim verisinde bile altta yatan örüntüyü yakalayamayan model ise **yetersiz öğrenme (underfitting)** sorunu yaşar. (A model that learns the training data too well, capturing noise and random fluctuations, suffers from overfitting. A model that fails to capture the underlying pattern, even on the training data, suffers from underfitting.)
2. Bir modelin daha önce görmediği veriler üzerinde iyi performans gösterme yeteneğine **genelleme (generalization)** denir. (The ability of a model to perform well on unseen data is called generalization.)
3. Aşırı öğrenmeyi azaltmak için yaygın stratejiler arasında **düzenleştirme (regularization)**, **seyreltme (dropout)** (sinir ağları için), **erken durdurma (early stopping)** ve daha fazla **eğitim verisi (training data)** kullanmak sayılabilir. (Herhangi iki kabul edilir.) (Common strategies to reduce overfitting include regularization, dropout (for neural networks), early stopping, and using more training data. Any two acceptable answers.)
4. **Aşırı parametrelendirme (over-parameterization)**, modelin eğitim örneklerinden daha fazla parametreye sahip olması durumunu ifade eder; düzenlenilmezse sıklıkla aşırı öğrenmeye yol açar. (**Over-parameterization** describes a model with more parameters than training examples, often leading to overfitting if not regularized.)
5. Eğitim hatası ile test hatası arasındaki farka **genelleme açıklığı (generalization gap)** denir. Büyük bir fark **aşırı öğrenme (overfitting)** belirtisidir. (The difference between training error and test error is called the generalization gap. A large gap indicates overfitting.)
6. Polinomsal regresyonda karmaşık bir veri setinde 1. dereceden bir model büyük ihtimalle yetersiz öğrenirken, 20. dereceden bir model büyük ihtimalle **aşırı öğrenir (overfit)**. (In polynomial regression, a degree-1 model on a complex dataset will likely underfit, while a degree-20 model will likely overfit.)

5 Algoritmalar ve Özellikleri (Algorithms and Their Properties)

1. **Algoritma–Görev Eşleştirme:** Her algoritmayı en uygun görev tanımıyla eşleştiriniz. Boşluğa harfi yazınız. (**Algorithm–Task Matching:** Match each algorithm with the most appropriate task description. Write the letter in the blank.)
 - (a) Destek Vektör Makineleri (SVM) C
 - (b) k-En Yakın Komşu (k-NN) D

- (c) Karar Ağacı (Decision Tree) **B**
- (d) k-Ortalamalar (k-Means) **A**
- (e) Naive Bayes **E**

Görevler / Tasks:

- A. Etiketsiz veriyi k kümeye gruplandırma. (Group unlabeled data into k clusters.)
 - B. Veriyi özellik eşiklerine göre yinelemeli olarak böler; hem sınıflandırma hem regresyon yapabilir. (Recursively split data by feature thresholds; handles both classification and regression.)
 - C. Sınıflandırma için maksimum marjınli hiper-düzlemi bulur. (Find the maximum-margin hyperplane for classification.)
 - D. En yakın k eğitim örneğinin çoğunluk oylamasıyla sınıflandırma yapar. (Classify by majority vote among the k closest training examples.)
 - E. Bayes teoremini güçlü (naive) özellik bağımsızlığı varsayımıyla uygular. (Apply Bayes' theorem with strong (naive) feature independence assumption.)
2. Destek Vektör Makineleri doğası gereği **ikili (binary)** sınıflandırıcılardır, ancak bire-karşı-bir veya bire-karşı-hepsi stratejileriyle çok sınıflı duruma genişletilebilirler. (SVM is inherently a **binary** classifier, but can be extended to multi-class using one-vs-one or one-vs-rest strategies.)
 3. k-NN algoritması bir **örnek tabanlı (instance-based)** (veya tembel (lazy)) öğrenme örneğidir; çünkü eğitim verisini saklar ve hesaplamayı tahmin zamanına erteler. (The k-NN algorithm is an example of **instance-based** (or lazy) learning because it stores the training data and defers computation until prediction time.)
 4. Karar ağaçları aşırı öğrenmeye yatkındır; bu genellikle **budama (pruning)** veya yaprak başına minimum örnek sayısı belirleyerek kontrol edilir. (Decision trees are prone to overfitting, which is often controlled by **pruning** or setting a minimum number of samples per leaf.)
 5. Rastgele Orman (Random Forest) ve Gradyan Artırma (Gradient Boosting) gibi topluluk yöntemleri, dayanıklılığı ve doğruluğu artırmak için çok sayıda **karar ağacı (decision tree)** birleştirir. (Ensemble methods such as Random Forest and Gradient Boosting combine many **decision trees** to improve robustness and accuracy.)
 6. PCA (Principal Component Analysis) algoritması, verideki maksimum **varyans (variance)** yönleri olan **temel bileşenleri (principal components)** çıktı olarak verir. (The PCA algorithm outputs **principal components**, which are directions of maximum **variance** in the data.)
 7. Anomali tespiti için **İzolasyon Ormanı (Isolation Forest)** özellikleri rastgele bölerek anormallikleri açıkça izole eder; buna karşılık **Tek-Sınıf SVM (One-Class SVM)** normal verinin etrafında bir sınır öğrenir. (For anomaly detection, **Isolation Forest** explicitly isolates anomalies by randomly partitioning features, whereas **One-Class SVM** learns a boundary around the normal data.)

Bonus (İsteğe Bağlı / Optional)

1. Ayrı bir test kümesi tutmamızın ve onu asla model seçimi için kullanmamamızın nedenini bir cümleyle açıklayın. (Explain in one sentence why we keep a separate test set and never use it for model selection.) **Modelin daha önce görmediği veriler üzerindeki başarımının yansız bir tahmin**